MBA
USP
ESALQ

Técnicas de Machine Learning

Prof. Dr. Wilson Tarantin Junior

Leonardo Ferreira Lima 389.[illegible]198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Eduardo Ferreira Lima - 370.198-27

Machine learning

- Definição
  - Podem ser encontradas muitas definições para o conceito *machine learning*
  - Porém, em termos de seus objetivos, pode-se entender como a utilização dos dados e de algoritmos para a produção de informações que serão relevantes para a tomada de decisão
    - Informações úteis para uma melhor tomada de decisão (*data-driven decision making*)
    - Por exemplo: criando modelos preditivos e/ou analisando a interdependência entre os dados

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Banco de dados

- Definição e composição
  - O banco de dados é o objeto onde estão armazenadas as informações de interesse para a análise ou estudo em questão
  - Em muitos casos, o banco de dados contém uma **amostra**, ou seja, é um subconjunto extraído da população
  - O banco de dados é composto por variáveis e por observações
    - **Observações**: as unidades que têm suas características e atributos medidos
    - **Variáveis**: características/atributos observados, medidos ou categorizados

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Banco de dados: exemplos

- Bancos de dados sobre:
    - Pessoas
    - Países
    - Empresas
    - Tarefas
    - Ações da bolsa
    - ...

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Banco de dados

- Estrutura para uso
  - Normalmente, o banco de dados é estruturado com as variáveis em colunas e as observações em linhas em uma estrutura tabular

	Idade	Altura	Cidade	Profissão	Renda	...
Pessoa 1						
Pessoa 2						
Pessoa 3						
Pessoa 4						
Pessoa 5						
Pessoa 6						
Pessoa 7						
Pessoa 8						
Pessoa 9						
Pessoa 10						
...						

Eduardo Ferreira Lima 283.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tipos de variáveis

- As variáveis podem ser divididas em
  - **Métricas**: são as variáveis quantitativas, isto é, apresentam características que podem ser mensuradas ou contadas
  - **Não métricas**: são as variáveis qualitativas, sendo que indicam características que não podem ser medidas. Tais variáveis contêm categorias, por isto, muitas vezes, são chamadas de variáveis categóricas
  - **A identificação do tipo de variável é fundamental para a escolha da técnica que será utilizada na análise dos dados**

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Tipos de variáveis: exemplos

- **Métricas (quantitativas)**
  - Idade em anos
  - Renda mensal em Reais
  - Número de habitantes no município
  - Distância em metros entre duas cidades
  - Rentabilidade percentual diária de uma ação na bolsa

- **Não métricas (qualitativas)**
  - Nacionalidade
  - Cor do veículo
  - Profissão
  - Grau de escolaridade
  - Respostas sim ou não a um questionário
  - Escalas likert

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Variáveis qualitativas

- Características principais
  - As variáveis qualitativas têm sua representação feita por meio de tabelas de distribuição de frequências ou gráficos
    - Não é possível calcular medidas de resumo como média ou desvio padrão para variáveis qualitativas
  - As tabelas de frequências apresentam as contagens observadas por categoria da variável

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Variáveis quantitativas

- Características principais
  - As variáveis quantitativas podem ser representadas por diversas ferramentas, como gráficos, medidas de posição e dispersão
  - A seguir, alguns exemplos de estatísticas descritivas
    - Medidas de posição: média, mediana, quartis
    - Medidas de dispersão: variância e desvio padrão

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Detalhando as variáveis

- Outras características relevantes
  - Variáveis qualitativas: dicotômica ou policotômica; nominal ou ordinal
    - Dicotômica: duas categorias (binária); Policotômica: mais de duas categorias
    - Nominal: não estabelece relação de grandeza/ordem; Ordinal: estabelece ordem
  - Variáveis quantitativas: discretas ou contínuas
    - Discretas: possuem conjunto finito e numerável de valores, em geral, são obtidas a partir de dados de contagem (0, 1, 2, 3, 4, 5...)
    - Contínuas: assumem valores pertencentes ao intervalo de números reais

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Introdução ao Spyder IDE

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Apresentação

- **Python**: é a linguagem de programação que vamos utilizar
- Neste curso, vamos implementá-lo por meio do **Spyder (IDE)**
    - Software que torna o uso do Python mais simples para o usuário

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Ajuste: View > Window layouts > Rstudio

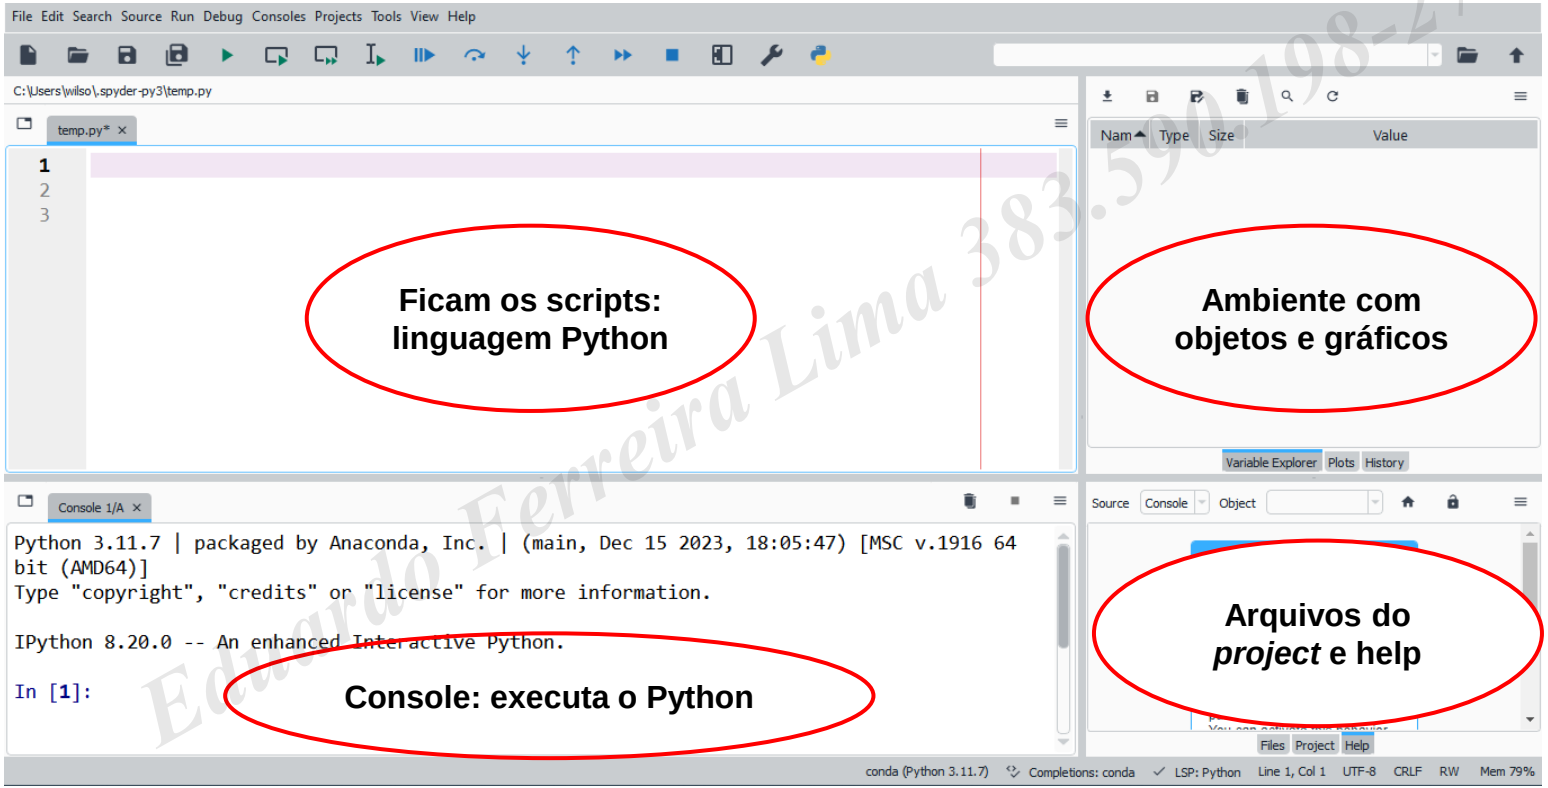

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Acessando um *project*

- Sempre que acessar um projeto em execução, acesse o *project*:

1. Retire a pasta do arquivo compactado (caso esteja);
2. No Spyder acesse: Projects > Open Project > Selecione a pasta
3. Os arquivos contidos no *project* aparecerão no ambiente

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Pacotes

- Alguns pacotes que utilizaremos:
  - Pandas: manipulação e análise de dados
  - Numpy: funções matemáticas e dados
  - Matplotlib: visualização de dados em gráficos
  - Seaborn: também é um pacote gráfico
  - Plotly: gráficos interativos

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Documentação

- Leituras e documentação para consulta
  - https://pandas.pydata.org/docs/index.html
  - https://numpy.org/doc/stable/
  - https://matplotlib.org/
  - https://seaborn.pydata.org/
  - https://plotly.com/python/

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Modelos Lineares de Regressão Simples e Múltipla

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Modelos lineares de regressão

- Modelos supervisionados de machine learning
  - Conhecidos como modelos confirmatórios ou técnicas de dependência
  - O objetivo é estimar modelos, equações, com o intuito de elaborar previsões
    - Portanto, há inferência dos resultados para outras observações fora da amostra
  - Define-se uma relação ***Y = f(X)***
    - **Y**: chamada de variável dependente, é a variável a ser explicada (*target*)
    - **X**: chamadas de variáveis explicativas, são as preditoras (*features*)

Eduardo Ferreira Lima 583.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Quando aplicar o modelo

- A regressão linear é aplicada quando a **variável dependente é quantitativa**
    - O objetivo é explicar o comportamento de Y em função de um conjunto de X
    - Estabelece-se uma relação linear entre as variáveis
- Regressão linear simples e múltipla
    - A regressão linear simples contém apenas uma variável explicativa
    - A regressão linear múltipla contém mais de uma variável explicativa

Eduardo Ferreira Lima 283.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Modelo geral de regressão linear

$$Y_i = a + b_1.X_{1i} + b_2.X_{2i} + \ldots + b_k.X_{ki} + u_i$$

- Y é a variável dependente quantitativa
- a representa a constante (intercepto)
- b_k representam os coeficientes para cada variável explicativa
- X_k representam as variáveis explicativas do modelo
- u_i representa o termo de erro do modelo (resíduo)
    - k é o número de variáveis explicativas e i refere-se às observações em análise
- As variáveis explicativas (X) podem ser métricas ou categóricas

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Mínimos quadrados ordinários (MQO)

- O algoritmo estimará os parâmetros **α** e **β** do modelo

$$\hat{Y}_i = \alpha + \beta . X_i$$

- Pode-se definir o resíduo do modelo para dada observação *i*

$$u_i = Y_i - \hat{Y}_i$$

- Condições para a estimação dos parâmetros do modelo (MQO)

1. **A somatória dos resíduos deve ser igual a zero**
2. **A somatória dos resíduos ao quadrado é a mínima possível**

Pode ser visto como P.O.

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Visualizando graficamente

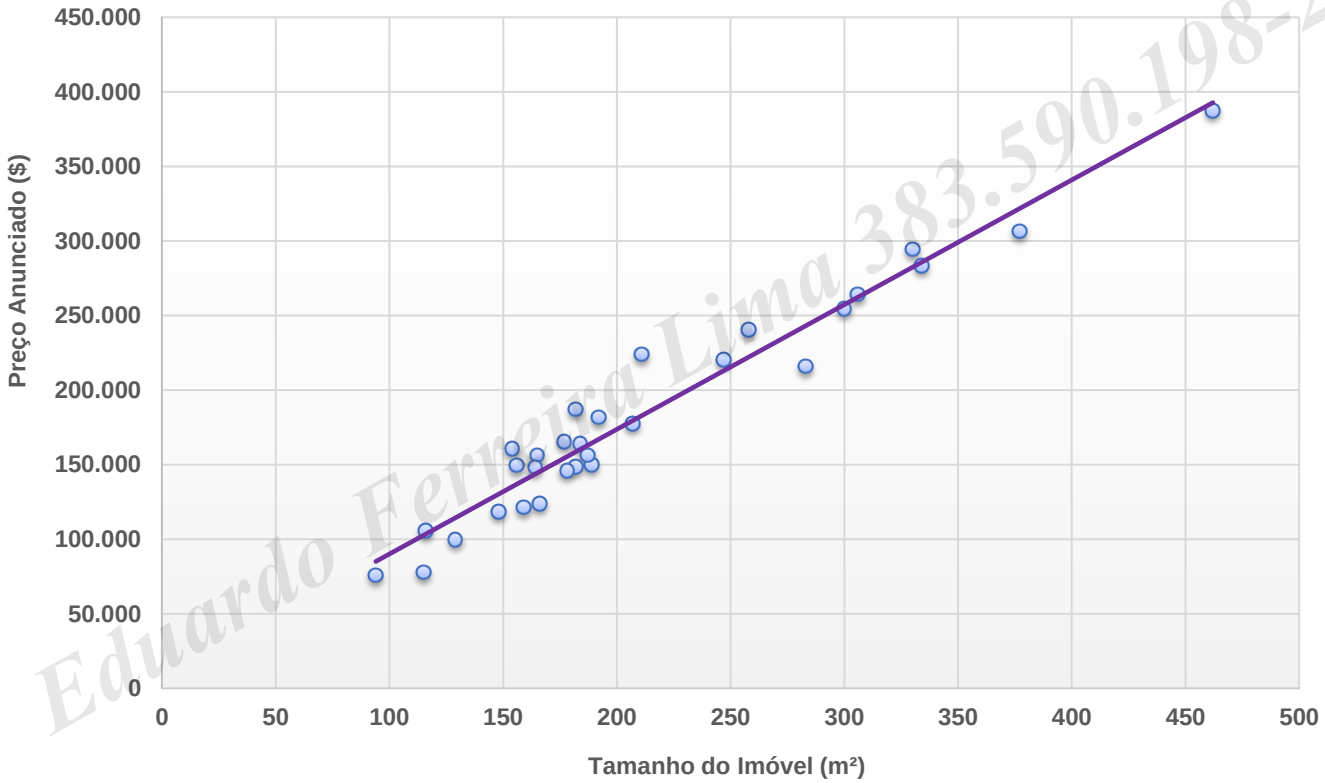

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Elementos de um modelo

- Interpretaremos
    - Coeficientes estimados
    - Significância geral do modelo (teste F – ANOVA)
    - Significância dos parâmetros (testes t)
    - Intervalos de confiança
    - Poder explicativo do modelo (R^2)

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Parâmetros do modelo

- Interpretação dos parâmetros α e β
  - α é o coeficiente linear, ou seja, o valor de Y caso todas as X=0
    - Muitas vezes, o α pode ser interpretado como a projeção da reta no eixo Y, uma vez que não encontram-se observações da amostra com todas as variáveis X=0
  - β são os coeficientes angulares, ou seja, a inclinação da reta
    - Na regressão múltipla, os β são interpretados na condição *ceteris paribus*, ou seja, o efeito daquela X sobre Y mantidas todas as demais variáveis constantes
    - Destaca-se que a interpretação dos parâmetros do modelo deve ocorrer sem a extrapolação dos dados, isto é, vale dentro do limite de variação das variáveis

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Teste F (ANOVA)

- Avalia a significância geral do modelo de regressão, ou seja, se pelo menos um dos **β** estimados é estatisticamente diferente de zero

$$F = \frac{\frac{SQR}{(k-1)}}{\frac{SQU}{(n-k)}}$$

SQR: Soma dos Quadrados da Regressão
SQU: Soma dos Quadrados dos Resíduos
k: nº de parâmetros do modelo (inclui α)
n: tamanho da amostra

  - H_0: β1 = β2 = ... = βk = 0
  - H_1: existe pelo menos um βj ≠ 0

- Normalmente, adota-se o nível de significância de 5% para o teste
  - Se o p-valor do teste F < 0.05, rejeita-se H_0

Eduardo Ferreira Lima 385.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Teste F (ANOVA)

SQT = SQR + SQU

- **Soma dos Quadrados Totais (SQT)**: variação de Y em torno de sua média
- **Soma dos Quadrados da Regressão (SQR)**: variação de Y considerando as variáveis X
- **Soma dos Quadrados dos Resíduos (SQU)**: variação de Y que não é explicada pelo modelo

$$\underbrace{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}_{\text{SQT}} = \underbrace{\sum_{i=1}^{n}(\widehat{Y}_i - \overline{Y})^2}_{\text{SQR}} + \underbrace{\sum_{i=1}^{n}(Y_i - \widehat{Y}_i)^2}_{\text{SQU}}$$

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Teste t

- Avalia a significância individual dos parâmetros estimados

$$t_{\alpha} = \frac{\alpha}{s.e.(\alpha)} \qquad t_{\beta_j} = \frac{\beta_j}{s.e.(\beta_j)}$$

  - H_0: $\alpha = 0$
  - H_1: $\alpha \neq 0$
  - H_0: $\beta_j = 0$
  - H_1: $\beta_j \neq 0$

- Adota-se o nível de significância de 5% para o teste

  - Se o p-valor do teste t < 0.05, rejeita-se H_0
  - **Mesmo que não tenha significância, o α não deve ser removido do modelo!**

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Intervalos de confiança

- Para o nível de confiança escolhido, é o intervalo de valores que contém o verdadeiro parâmetro populacional

$$\alpha \pm t \times s.e.(a)$$

$$\beta_j \pm t \times s.e.(\beta_j)$$

  - t é o valor crítico bicaudal da distribuição t de Student para o nível de confiança escolhido na análise, com n – k graus de liberdade
    - Normalmente, observa-se o nível de confiança de 95% (nível de significância de 5%)

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Coeficiente de explicação (R^2)

- O R^2 apresenta o poder explicativo do modelo, ou seja, o percentual da variabilidade de Y que é explicado pela variação das variáveis X

$$R^2 = \frac{SQR}{SQR + SQU}$$

  - O R^2 varia entre 0 e 1: valores mais próximos de 1 indicam maior capacidade preditiva
    - O R^2 não deve ser analisado no sentido de validar ou não o modelo, pois, em muitos campos do conhecimento, é comum não obter valores muito elevados
  - R^2 ajustado para comparação entre modelos: $R^2_{ajust} = 1 - \frac{n-1}{n-k}(1 - R^2)$
    - Ajusta-se a quantidade *k* de parâmetros (incluindo o α) e o tamanho da amostra *n*

Eduardo Ferreira Lima 385.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Variáveis explicativas categóricas

- Quando há variáveis X categóricas, é necessário transformá-las em *dummies*
  - *Dummy:* variável binária (1 ou 0) indicando a presença ou ausência do atributo

ID	Variável A		Variável B		
	Categ. 1	Categ. 2	Categ. 1	Categ. 2	Categ. 3
1	1	0	0	1	0
2	0	1	0	0	1
3	0	1	1	0	0
4	1	0	0	0	1
5	0	1	0	1	0
6	1	0	1	0	0

Na regressão, utiliza-se o procedimento de **n-1 *dummies***, ou seja, uma das categorias de cada variável categórica fica como a referência de sua variável no intercepto

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Referência

Fávero, Luiz Paulo; Belfiore, Patrícia. (2024). Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 2 ed. Rio de Janeiro: LTC.

Eduardo Ferreira Lima 383.590.198-27

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

OBRIGADO!

Eduardo Ferreira Dias 383.590.198-27