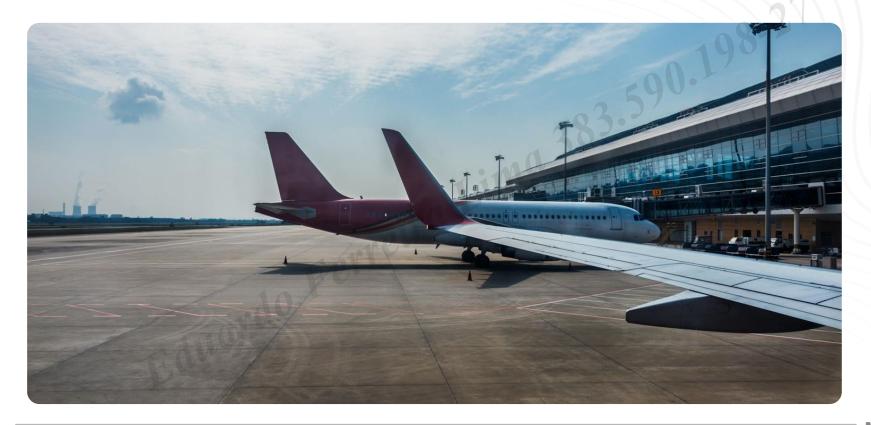
# Observabilidade e Monitoramento

Prof. Helder Prado Santos

\*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

**Proibida a reprodução,** total ou parcial, sem autorização. Lei nº 9610/98

# Do desenvolvimento para produção



# Do desenvolvimento para produção



# Do desenvolvimento para produção





### Monitoramento

- Monitoramento é o processo de coletar, analisar e usar dados sobre o desempenho de um sistema, infraestrutura ou aplicação com base em métricas predefinidas.
- O objetivo é detectar anomalias, falhas e problemas de desempenho. Ele se baseia em alertas configurados antecipadamente, sendo eficaz para monitorar eventos e condições específicas.



### Características do Monitoramento

- Proativo: O monitoramento é configurado para observar métricas-chave, como uso de CPU, memória, tempo de resposta e disponibilidade.
- **Métricas Definidas**: Baseia-se em métricas pré-configuradas, como uso de recursos, contagem de erros ou latência.
- Alertas: Envia notificações automáticas quando essas métricas ultrapassam limites estabelecidos (por exemplo, CPU acima de 80%).
- Visão Superficial: Ele oferece uma visão clara sobre a "saúde" do sistema, mas é limitado àquilo que foi previamente configurado para monitorar. Se um problema não foi antecipado, ele pode passar despercebido.

### Observabilidade

- OBSERVABILIDADE é um conceito mais amplo e profundo, focado na capacidade de entender o comportamento interno de um sistema complexo apenas examinando suas saídas (logs, métricas, traces).
- Enquanto o monitoramento mede coisas predefinidas, a observabilidade permite que você descubra problemas não antecipados, explorando dados mais detalhados.





### Observabilidade vs Monitoramento

Característica	Monitoramento	Observabilidade
Foco	Métricas e eventos predefinidos	Diagnóstico e entendimento do sistema
Objetivo	Detectar anomalias e falhas conhecidas	Explorar e diagnosticar comportamentos desconhecidos
Coleta de Dados	Métricas simples e limites	Logs, métricas e tracing (dados ricos e detalhados)
Alertas	Baseados em limiares predefinidos	Suporte à exploração e investigação de falhas
Visão	Limitada ao que foi configurado	Ampla, cobrindo vários tipos de dados
Abordagem	Proativa (monitora e alerta)	Reativa e exploratória (permite investigação profunda)
Adequado para	Problemas conhecidos e limiares previsíveis	Problemas complexos e emergentes



### Observabilidade vs Monitoramento

#### **Exemplo de monitoramento:**

 Você configura um monitoramento para alertá-lo se o uso da CPU de um servidor ultrapassar 90%. Quando esse limite é atingido, você recebe um alerta para investigar.

#### **Exemplo de Observabilidade:**

 Ao notar que o tempo de resposta de uma aplicação está aumentando, você usa ferramentas de observabilidade para investigar os logs, traces e métricas de múltiplos serviços e descobre que o problema está em uma interação lenta com o banco de dados.

### É como se...

- Monitoramento é como um sistema de alarme: ele é configurado para soar quando algo específico dá errado (como portas abertas ou movimento detectado). Ele avisa se algo conhecido falha, mas não pode prever o inesperado.
- Observabilidade é como uma câmera de segurança inteligente: ela grava todos os eventos e você pode investigar o que aconteceu mesmo que o alarme não tenha soado. Se houver um comportamento estranho que você não antecipou, você tem os dados para analisá-lo e entender melhor o que ocorreu.

# O que preciso monitorar?

Os 4 sinais de SRE (Site Reliability Engineers)

- Latência;
- 2. Tráfego;
- 3. Erros;
- 4. Saturação.



Link do livro: <a href="https://sre.google/sre-book/table-of-contents/">https://sre.google/sre-book/table-of-contents/</a>



### Os 3 Pilares da Observabilidade



MBA USP ESALO

# Pilar: Logs

 Logs são registros textuais gerados por aplicações, sistemas operacionais, servidores ou outros componentes de software para descrever eventos, ações e estados ocorridos em determinado momento.

aduardo Ferreir



# Pilar: Logs

Os logs geralmente incluem informações como:

- > Timestamp (Data e Hora): Quando o evento ocorreu.
- Nível de Log: Indica a severidade do evento, como INFO, DEBUG, ERROR, WARNING, etc.
- Mensagem: Uma descrição do evento, o que aconteceu ou o status do sistema.
- Contexto: Informações adicionais como ID de usuário, nome do serviço, ou qualquer dado que ajude a identificar a causa ou impacto do evento.

# Pontos Importantes do Pilar Logs

#### **Coleta Eficiente de Logs:**

- Centralização de Logs;
- Correlação de Logs.

#### Estruturação dos Logs:

- Logs Estruturados;
- Níveis de Severidade.

### Retenção e Rotação de Logs:

- Política de Retenção de Logs;
- Rotação de Logs.



# Pontos Importantes do Pilar Logs

#### **NÍVEIS DE LOG:**

- DEBUG: Informações detalhadas usadas para depuração.
- INFO: Informações sobre operações normais.
- WARNING: Potenciais problemas que não afetam o sistema, mas podem necessitar de atenção.
- ERROR: Erros que impactam partes do sistema, mas não o desativam completamente.
- CRITICAL/FATAL: Erros críticos que podem resultar em falha total ou interrupção significativa do serviço.



### **Pilar: Métricas**

- Métricas são medições quantificáveis de um sistema. Elas fornecem uma visão em tempo real de como os recursos estão sendo utilizados e como as aplicações estão se comportando, facilitando a detecção de anomalias e o diagnóstico de problemas.
- As métricas são simples, agregadas e leves em termos de armazenamento, sendo ideais para monitoramento contínuo.





# Categorias de métricas

#### **Métricas de Sistema** (Infraestrutura):

- CPU: Percentual de uso de CPU de uma máquina ou serviço;
- Memória: Quantidade de memória sendo utilizada;
- Rede: Quantidade de dados sendo enviados e recebidos;
- Disco: Espaço em disco disponível e taxa de leitura/gravação;
- ... entre muitas outras.



# Categorias de métricas

#### Métricas de Aplicação:

- Taxa de Erros: Percentual de requisições que resultaram em erros;
- Latência: Tempo médio de resposta de uma requisição;
- Taxa de Requisições: Quantidade de requisições recebidas por segundo;
- Uso de Banco de Dados: Consultas por segundo, tempo de resposta de queries, conexões abertas;
- ... entre muitas outras.



# Categorias de métricas

#### Métricas de Negócios:

- Número de Usuários Ativos: Quantidade de usuários acessando a plataforma;
- Transações Completadas: Quantidade de compras ou ações importantes realizadas pelos usuários;
- Conversão: Percentual de visitantes que realizaram uma ação desejada;
- Receita por Minuto: Valor monetário gerado em um período específico;
- ... entre muitas outras.



# Tipos de Métricas

#### **Métricas Contínuas**

 Representam valores que podem variar em intervalos contínuos de tempo.

Exemplo: Uso de CPU ou latência de requisição.

#### Métricas de Contagem

São incrementadas ou acumuladas ao longo do tempo.
Exemplo: Número de requisições processadas por um serviço.

#### **Métricas Derivadas**

Calculadas a partir de outras métricas.
Exemplo: Taxa de erro derivada de dividir o número de erros pelo total de requisições.



### Pilar: Métricas

# Integração de métricas de diferentes categorias

- Se houver um aumento na latência de requisição, isso pode impactar negativamente a taxa de conversão de vendas.
- Se o uso de CPU estiver muito alto, isso pode afetar o tempo de resposta ao cliente e, assim, aumentar o churn de clientes.





# Pontos importantes pilar Métricas

#### Coleta de Métricas

- Automatização
- Granularidade

### Monitoramento de Limiares (Thresholds)

- Alertas Baseados em Limiares
- Alertas Dinâmicos

#### Visualização

Gráficos e Dashboards



### Benefícios de Monitorar Métricas

- Detecção Precoce de Problemas: Monitorar métricas permite identificar falhas ou degradações de desempenho antes que elas impactem usuários.
- Aprimoramento Contínuo: O monitoramento regular de métricas ajuda a identificar padrões de uso e possíveis otimizações.
- Escalabilidade: Métricas de infraestrutura ajudam a planejar o escalonamento de recursos à medida que o sistema cresce.



### Métricas, SLA e SLO

- SLA (Acordo de Nível de Serviço): É um contrato formal entre um provedor de serviço e um cliente que define o nível de serviço esperado. Geralmente, inclui penalidades ou compensações se esses níveis de serviço não forem atingidos. Um exemplo comum é um SLA que garante 99,9% de disponibilidade de um serviço ao longo de um mês.
- SLO (Objetivo de Nível de Serviço): É um subconjunto de um SLA, focando nos objetivos que o provedor de serviço define para manter o acordo. Ele define metas técnicas mensuráveis, como tempo de resposta, taxa de erro, disponibilidade, etc. O SLO é a métrica que se monitora para verificar se o SLA está sendo cumprido.



# Métricas como Base para Definir SLOs

 As métricas coletadas no sistema ao longo do tempo fornecem dados históricos que ajudam a definir SLOs realistas.

#### POR EXEMPLO:

Se as métricas históricas mostram que a latência média de uma aplicação é **150ms**, um SLO de **200ms de latência máxima** pode ser estabelecido com confiança.

### Exemplos de Métricas Relacionadas a SLOs e SLAs

#### Disponibilidade (Uptime)

- SLO: O sistema deve estar disponível 99,9% do tempo.
- Métrica: Monitorar o uptime e o downtime do sistema
- SLA: O SLA define que, se a disponibilidade cair abaixo de 99,9%, o provedor do serviço será penalizado (por exemplo, descontos para o cliente).



## Exemplos de Métricas Relacionadas a SLOs e SLAs

#### Latência

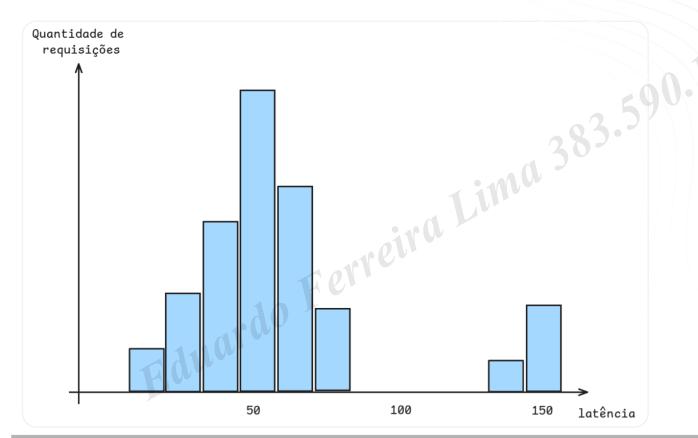
- SLO: O tempo de resposta de uma requisição não deve ultrapassar 200ms em 95% das vezes.
- Métrica: Monitorar a latência média e os percentis (por exemplo, P95, P99) de resposta da aplicação.
- **SLA**: O SLA pode estipular que, se a latência exceder 200ms consistentemente, compensações ou melhorias devem ser implementadas.



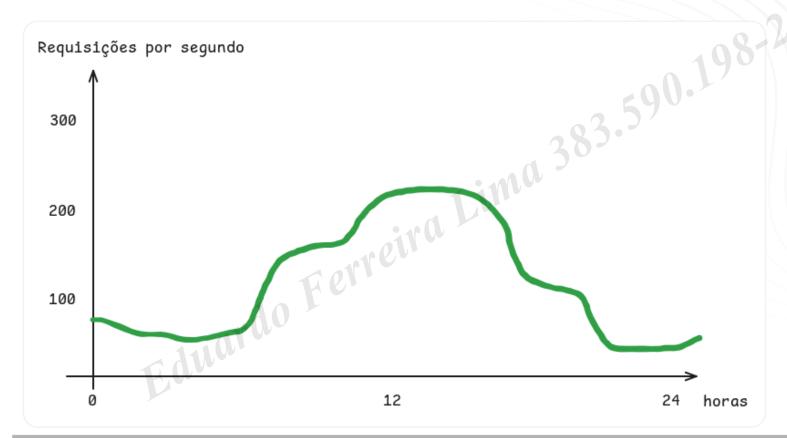
# Benefícios de Utilizar Métricas para Monitorar SLA e SLO

- Transparência e Confiança: As métricas permitem monitorar o cumprimento de SLOs de forma objetiva, garantindo que os clientes saibam que o serviço está funcionando conforme prometido no SLA.
- Proatividade: Com as métricas monitoradas em tempo real, as equipes de operação podem ser proativas e corrigir problemas antes que eles violem um SLA.
- Evolução Contínua: O acompanhamento das métricas ao longo do tempo permite que os SLOs sejam ajustados para refletir melhorias na infraestrutura ou necessidades de negócios, e os SLAs sejam atualizados de forma coerente.

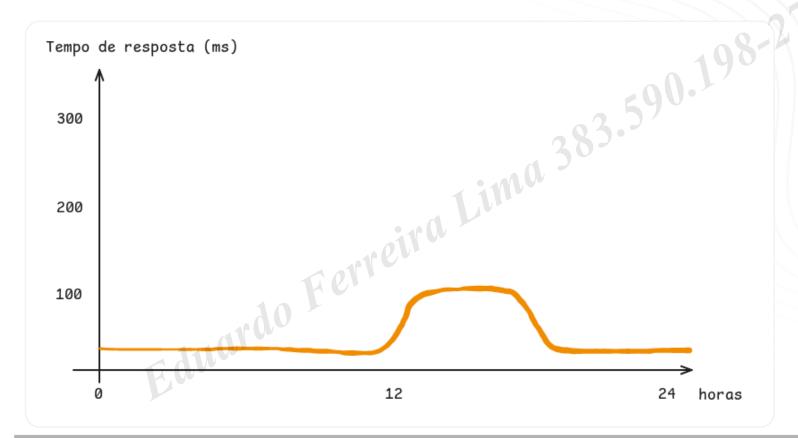




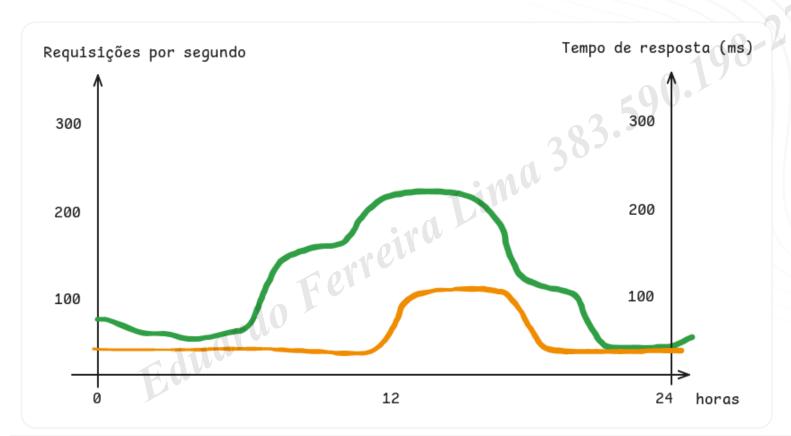
MBAUSP ESRLO







MBA USP ESALO









# Administrando possíveis riscos com alertas





#### Detecção de Incidentes

- O objetivo principal de um alerta é detectar rapidamente incidentes ou potenciais falhas, como picos de latência, aumento da taxa de erro, ou quedas na disponibilidade de um sistema.
- Alertas são disparados quando uma condição específica, geralmente definida por métricas ou logs, ultrapassa um limiar ou atende a uma regra configurada.

#### Condições e Regras de Alerta

- Um alerta é configurado com base em condições que refletem o comportamento esperado do sistema. Por exemplo:
  - Se a CPU de um servidor estiver acima de 90% por mais de 5 minutos.
  - Se a taxa de erro de uma API for maior que 1% das requisições.

#### **Tipos de Alertas**

- Alertas por Métricas: Baseados em valores numéricos que indicam a performance ou estado do sistema.
  Exemplo: taxa de erro, uso de CPU, tempo de resposta.
- Alertas por Logs: Disparados quando padrões ou palavras-chave específicas aparecem nos logs do sistema, indicando possíveis erros ou exceções.
- Alertas por Traces: Usados para identificar lentidão em fluxos de transações distribuídas ou outros problemas relacionados a dependências em microsserviços.



#### Severidade dos Alertas

- Informativo: Apenas para informar que algo diferente do normal foi detectado.
- Aviso: Indica que o sistema pode estar se aproximando de uma falha, mas ainda está operando dentro dos limites aceitáveis.
- Crítico: Necessita de ação imediata, pois o sistema está fora dos padrões operacionais e pode estar impactando usuários.



## Boas Práticas para Configuração de Alertas

- ✓ Evitar Alerta em Excesso (Alert Fatigue);
- ✓ Definir Limiares Claros;
- ✓ Priorizar Alertas Críticos;
- ✓ Automatização de Respostas;
- ✓ Integrar Alertas com Ferramentas de Notificação.





## Pilar: Rastreamento (Tracing)

- Tracing (ou rastreamento distribuído) é o processo de rastrear o caminho completo de uma requisição enquanto ela percorre os diferentes serviços e componentes de um sistema distribuído.
- O objetivo do tracing é monitorar e entender o comportamento de aplicações distribuídas, como microsserviços, identificando gargalos de desempenho, falhas, ou pontos de lentidão em todo o ciclo de vida de uma requisição.

## Pontos importantes

#### Transações Distribuídas

 Transações End-to-End: Tracing permite monitorar uma transação do início ao fim, através de múltiplos serviços. Isso inclui a captura de latência, falhas e o tempo de processamento em cada serviço ou componente.

#### SPAN E TRACE:

**Span**: Cada unidade de trabalho dentro de um trace. Um trace pode ser composto de vários spans, cada um representando uma etapa ou serviço da transação.

**Trace**: Representa o caminho completo de uma requisição através de diferentes serviços e spans.



## Pontos importantes do Tracing

#### **Correlações com Outras Métricas**

- Integração com Logs e Métricas
- Identificadores Correlacionados

#### Tempo de Execução e Latência

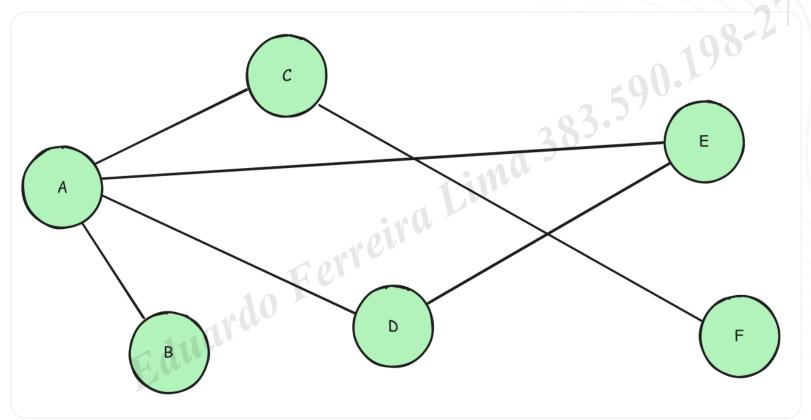
Análise de Latência de ponta a ponta

#### Diagnóstico de Problemas

- Identificação de Falhas
- Análise de Dependências

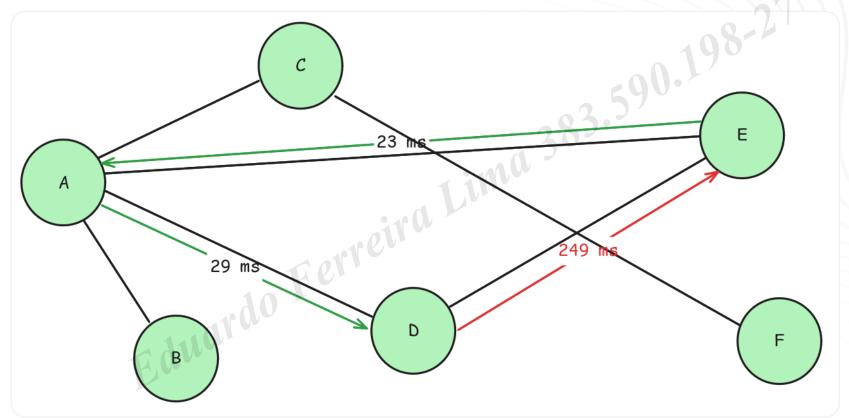


# Tracing na prática



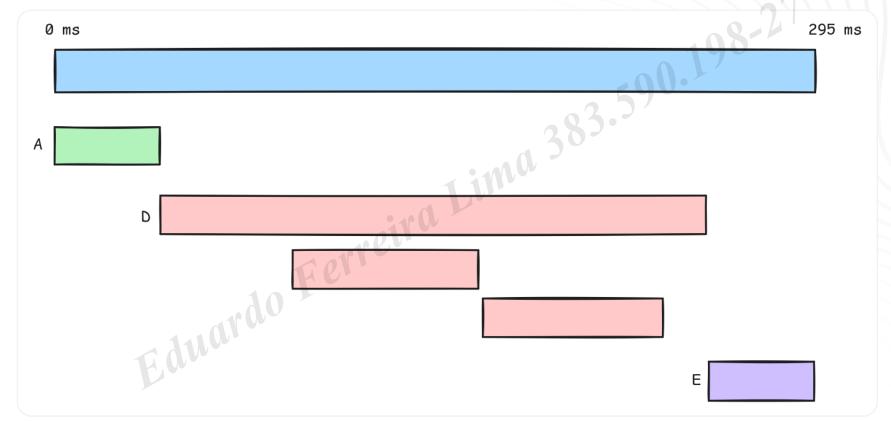


# Tracing na prática



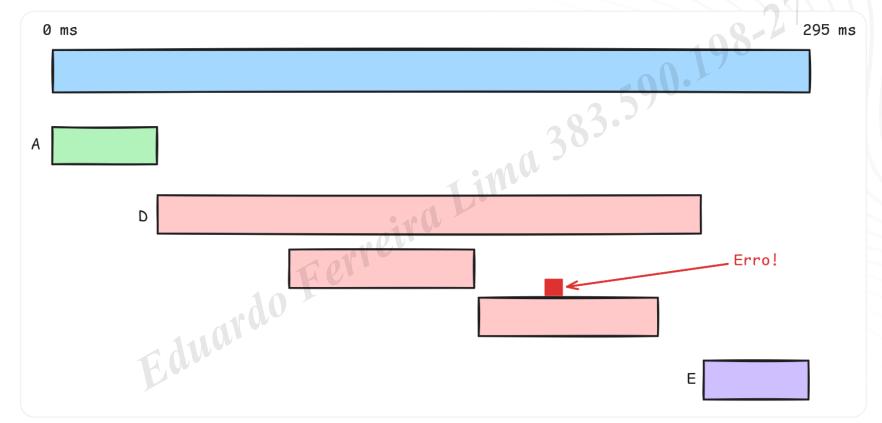


# Tracing na prática





## Identificando erros na transação





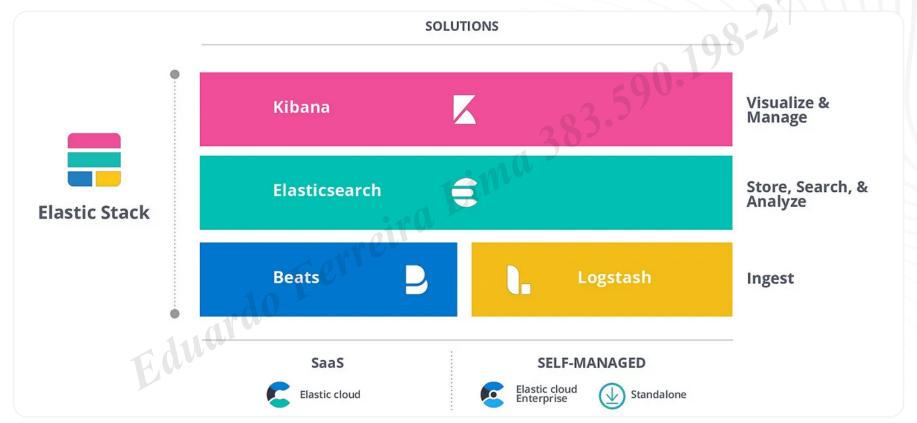
## Ferramentas de Observabilidade

- ✓ Datadog;
- ✓ New Relic;
- ✓ OpenTelemetry;
- ✓ Elastic Stack ELK.



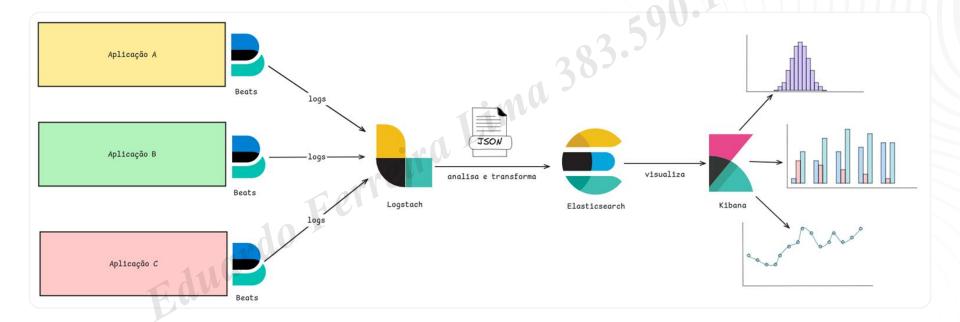


### **Elastic Stack ELK**



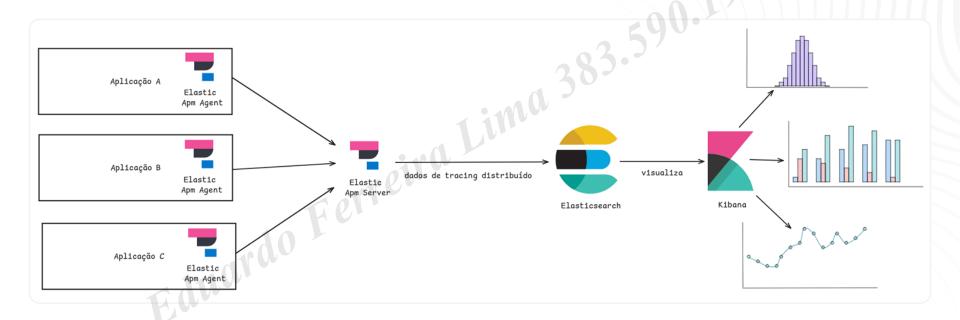
**MBAUSP** ESALO

# Processo de captação e visualização dos logs



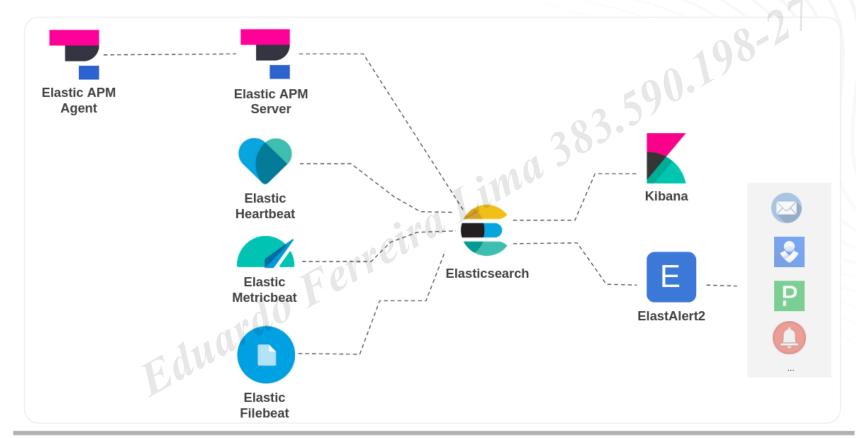


# Processo de captação e visualização do tracing distribuído



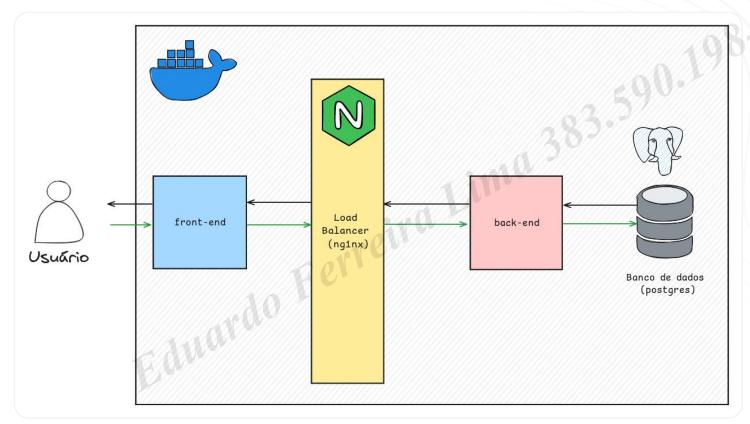


### Emitindo alertas com ElastAlert2





## Aplicação de Exemplo Prático



## Referências

- BEYER, B. et al. Engenharia de Confiabilidade do Google. [s.l.] Novatec Editora, 2019.
- 2. MAJORS, C. OBSERVABILITY ENGINEERING: achieving production excellence. S.L.: O'reilly Media, 2022.



## **OBRIGADO!**

linkedin.com/in/helderprado

